

Semana 14 02/05/26

Fundamentos y Algoritmos de Minería de Datos

Material Teórico para Estudio



Data Mining



Clustering



Clasificación



Asociación



Objetivos de Aprendizaje



Comprender qué es la minería de datos y su propósito



Conocer el proceso CRISP-DM estándar



Identificar algoritmos de clustering (K-Means, DBSCAN, Jerárquico)



Identificar algoritmos de clasificación (Árboles, K-NN, SVM, Naive Bayes)



Entender reglas de asociación y algoritmo Apriori



Reconocer aplicaciones y desafíos éticos

Definición y Conceptos Fundamentales

1.1 ¿Qué es la Minería de Datos?

La **Minería de Datos (Data Mining)** es el proceso de descubrir patrones, correlaciones, anomalías y tendencias significativas en grandes volúmenes de datos mediante técnicas estadísticas, matemáticas y de inteligencia artificial.

 **Definición formal:** Es la extracción no trivial de información implícita, previamente desconocida y potencialmente útil a partir de datos.

 **Analogía conceptual:** Así como la minería tradicional extrae minerales valiosos de la tierra, la minería de datos extrae conocimiento valioso de los datos.

1.2 Diferencias entre Análisis Tradicional y Minería de Datos

Aspecto	Análisis Tradicional	Minería de Datos
Enfoque	Confirmatorio (valida hipótesis)	Exploratorio (descubre patrones)
Pregunta típica	"¿Es verdad que...?"	"¿Qué patrones existen...?"
Volumen de datos	Pequeñas muestras	Grandes volúmenes (Big Data)
Técnica principal	Estadística descriptiva	Algoritmos de aprendizaje
Resultado	Reportes estáticos	Modelos predictivos y reglas
Interacción	Usuario define todo	Algoritmo ayuda a descubrir

1.3 Tipos de Conocimiento que se pueden extraer



Asociación
Relaciones entre eventos



Clasificación
Asignar a categorías



Clustering
Agrupar similares



Predicción
Estimar valores futuros



Detección de anomalías
Identificar outliers



Secuenciación
Patrones temporales

2

El Proceso CRISP-DM

1

Comprensión del Negocio

Definir objetivos, criterios de éxito, recursos y riesgos.

Pregunta clave: ¿Qué problema resolvemos?

2

Comprensión de los Datos

Recopilar, describir, explorar y verificar calidad de datos.

3

Preparación de los Datos

Seleccionar, limpiar, transformar y crear variables.

 **60-80% del tiempo del proyecto**

4

Modelado

Seleccionar técnicas, diseñar escenarios, construir y evaluar modelos.

5

Evaluación

Evaluar si cumple objetivos de negocio, revisar proceso, determinar próximos pasos.

6

Despliegue

Planificar implementación, monitoreo, mantenimiento y generación de reportes.

3

Algoritmos de Clustering (No Supervisado)

K-Means

Algoritmo que particiona los datos en K clusters, donde cada observación pertenece al cluster con la media más cercana (centroide).



Procedimiento:

1. Seleccionar K puntos aleatorios como centroides iniciales
2. Asignar cada punto al centroide más cercano
3. Recalcular centroides como media de puntos asignados
4. Repetir pasos 2-3 hasta convergencia



Rápido y escalable



Requiere especificar K



Sensible a outliers



Método del Codo: Evalúa la inercia para diferentes K. El punto donde la reducción se estabiliza indica el K óptimo.

DBSCAN

Algoritmo basado en densidad que agrupa puntos cercanos y marca como ruido puntos aislados.

Parámetros: ϵ (epsilon radio) y MinPts (mínimo puntos)



No requiere K



Clusters de formas arbitrarias



Maneja outliers

K-Medoids

Similar a K-Means pero usa objetos reales como centroides (medoides). Más robusto a outliers.

Clustering Jerárquico

Construye jerarquía de clusters mediante enfoque aglomerativo (combinando) o divisivo (dividiendo).

Tipos de enlace: Single-link, Complete-link, Average-link, Ward

4

Algoritmos de Clasificación (Supervisado)



Árboles de Decisión

Modelo predictivo en forma de árbol que usa preguntas sucesivas para llegar a una conclusión.

Algoritmos: ID3, C4.5, CART, CHAID

K-Vecinos Más Cercanos (K-NN)

Clasifica un nuevo elemento basándose en la mayoría de sus K vecinos más cercanos.

Parámetros: K (número de vecinos), métrica de distancia

 Fácil interpretación Propenso a sobreajuste Simple de entender Costoso computacionalmente

Naive Bayes

Clasificador probabilístico basado en el teorema de Bayes con suposición de independencia entre características.

Fundamento: $P(C|F) \propto P(C) \times \prod P(F|C)$

 Muy rápido Suposición de independencia

Máquinas de Vectores Soporte (SVM)

Encuentra el hiperplano que maximiza el margen entre clases.

Tipos de kernel: Lineal, Polinomial, RBF, Sigmoidal

 Bueno en alta dimensión Sensible a parámetros

5

Reglas de Asociación

5.1 Definición

Las reglas de asociación descubren relaciones entre elementos en transacciones, respondiendo "¿qué productos se compran juntos?"

5.2 Conceptos Fundamentales

Transacción: Conjunto de ítems comprados juntos

Itemset: Conjunto de uno o más ítems

Regla: $X \rightarrow Y$ (X e Y disjuntos)

5.3 Métricas de Evaluación

Métrica	Definición	Interpretación
Soporte	$\text{sup}(X) = \text{freq}(X)/\text{total}$	Popularidad del conjunto
Confianza	$\text{conf}(X \rightarrow Y) = \text{sup}(X \cup Y) / \text{sup}(X)$	Confiabilidad de la regla
Lift	$\text{lift}(X \rightarrow Y) = \text{sup}(X \cup Y) / (\text{sup}(X) \times \text{sup}(Y))$	> 1: asociación positiva

5.4 Algoritmo Apriori

Identifica itemsets frecuentes mediante propiedad: todos los subconjuntos de un itemset frecuente deben ser frecuentes.

Procedimiento: Generar itemsets tamaño 1 → filtrar → generar candidatos tamaño k+1 → filtrar → repetir

5.5 Algoritmo FP-Growth

Alternativa más eficiente que comprime la base de datos en una estructura de árbol (FP-Tree) para evitar generación de candidatos.



Aplicaciones por Industria



Retail

- Market Basket Analysis
- Segmentación de clientes
- Predicción de abandono
- Optimización de inventario

Finanzas

- Detección de fraudes
- Scoring crediticio
- Análisis de riesgo
- Segmentación de inversores

Salud

- Diagnóstico asistido
- Predicción de reingresos
- Patrones epidemiológicos
- Optimización de tratamientos



Telecomunicaciones

- Predicción de abandono
- Segmentación de uso
- Detección de fraudes
- Optimización de red



Manufactura

- Control de calidad predictivo
- Mantenimiento predictivo
- Optimización de procesos
- Detección de defectos



Educación

- Predicción de deserción
- Personalización de aprendizaje
- Análisis de rendimiento
- Recomendación de cursos

7

Desafíos y Consideraciones Éticas



Desafíos Técnicos

- Maldición de la dimensionalidad
- Overfitting (sobreajuste)
- Datos desbalanceados
- Datos faltantes



Consideraciones Éticas

- 🔒 Privacidad de datos personales
- li> ⚖️ Sesgo algorítmico y discriminación
- 🔍 Transparencia y explicabilidad
- 📝 Consentimiento informado

- Escalabilidad con grandes volúmenes

-  Responsabilidad en decisiones automatizadas

Buenas Prácticas

 Documentar todo el proceso CRISP-DM

 Validar modelos con datos no vistos

 Evaluar múltiples métricas, no solo exactitud

 Involucrar expertos de dominio

 Monitorear modelos en producción

 Actualizar modelos periódicamente

Preguntas de Repaso

1 ¿Cuál es la diferencia entre clustering y clasificación?

2 ¿Qué significa que un algoritmo es "supervisado" o "no supervisado"?

3 ¿Para qué sirve el método del codo en K-Means?

4 ¿Qué interpretación tiene un valor de Lift > 1 en reglas de asociación?

5 ¿Cuáles son las 6 fases del proceso CRISP-DM?