



Clase 1 - Semana 1

Machine Learning

Universidad de Oriente
Facultad de Ingeniería y Arquitectura

23 de enero del 2025


Unidad 1: Introducción a Machine Learning

El aprendizaje automático, también referido como machine learning, se puede considerar como la ciencia (y el arte) de programar computadoras de modo que puedan aprender a través de los datos (Geron 2019). Aunque en los últimos años ha tomado un gran impulso, su conceptualización no es tan moderna, y ya en 1959 ya se definía el aprendizaje automático como: “el campo de estudio que dota a las computadoras de la habilidad de aprender sin ser programadas explícitamente”.

Uno de los grandes hitos en el aprendizaje automático, fue la consecución de un filtro anti-spam para correos electrónicos mediante aprendizaje automático. Esta aplicación consigue entrenar a un programa mediante aprendizaje automático a través de ejemplos múltiples correos electrónicos marcados como spam por distintos usuarios y de ejemplos de correos que no son spam.

Unidad 1: Introducción a Machine Learning.

La diferencia frente a la programación tradicional es que en el aprendizaje automático no se programan unas características en concreto, sino que el programa aprende mediante los ejemplos, es decir, el conjunto de datos de entrenamiento.



Unidad 1: Introducción a Machine Learning




Figure: El enfoque del aprendizaje automático

Unidad 1: Introducción a Machine Learning

Si se quisiera intentar programar de manera tradicional los posibles patrones que aparecen en un correo spam, el código necesario sería muy complejo (por ejemplo, si se detecta que en muchos correos que son spam se emplea la palabra “gratis” o “asombroso” se podría añadir esta regla, pero al poco tiempo los creadores de spam cambiarían “gratis” por “sin coste” y habría que añadir una nueva regla, etc.).

Otro de los problemas en los que es mucho más eficiente abordarlo desde la perspectiva del aprendizaje automático es el reconocimiento de imágenes. Uno de los ejemplos más característicos es la clasificación entre gatos y perros.

Unidad 1: Introducción a Machine Learning

Si se quiere realizar un programa que cuando se cargue una imagen de un gato o de un perro detecte qué clase de animal es, sería muy complicado realizarlo mediante la definición de patrones. Se podría intentar programar: “si tiene orejas puntiagudas es un gato”. Pero ante la aparición de un perro con orejas puntiagudas el programa clasificaría incorrectamente. En este caso, la solución también se consigue mediante aprendizaje automático.

En resumen, el aprendizaje automático sirve para:

- Tratar con problemas cuya resolución requiera de un ajuste muy fino o de largas listas de reglas y excepciones
- Resolver problemas complejos que no tienen solución desde un enfoque tradicional.
- Entornos cambiantes: el aprendizaje automático se puede adaptar a nuevos datos

Unidad 1: Introducción a Machine Learning

Algunas de las aplicaciones concretas en las cuales se pueden aplicar las técnicas del machine learning son

- Estimación de la demanda de un producto, mediante técnicas de regresión, o mediante modelos de ensamble.
- Detección de fraude en tarjetas de crédito mediante técnicas de clasificación.
- Representación de conjuntos de datos multidimensionales complejos mediante técnicas de reducción de la dimensión.
- Segmentar clientes según sus patrones de compra mediante técnicas de clustering

Unidad 1: Introducción a Machine Learning

Y algunas otras, que aunque tienen su mayor grado de dificultad, también se resuelven mediante técnicas de machine learning

- Analizar imágenes de productos en una línea de producción y clasificarlas automáticamente mediante redes neuronales convolucionales (CNNs por sus siglas en inglés).
- Detección de tumores en un escáner cerebral, también mediante CNNs
- Clasificación automática de nuevos artículos mediante procesamiento del lenguaje natural (NLP, por sus siglas en inglés) y más específicamente, utilizando clasificación de textos empleando redes neuronales recurrentes (RNNs por sus siglas en inglés) o CNNs.
- Detección de lenguaje ofensivo en blogs o redes sociales, también mediante NLP.

Unidad 1: Introducción a Machine Learning

Existen distintos tipos de aprendizaje automático. Por un lado tenemos el aprendizaje supervisado, en el cual se etiquetan los datos y se buscan relaciones concretas entre ellos. En cambio, en el aprendizaje no supervisado, el sistema trata de aprender con datos sin etiquetar y extraer conclusiones. Para que quede más claro, se van a emplear dos ejemplos de clasificación:

- En un primer caso, supongamos que tenemos las características socioeconómicas de tres tipos de clientes según el tipo de servicio que ha contratado en nuestra empresa: clientes A, clientes B y clientes C.
- Un segundo problema, sería tener que clasificar a todos nuestros clientes, los cuales no tienen a priori ninguna etiqueta, y buscar grupos similares entre ellos. En este caso estaríamos ante un problema de aprendizaje automático no supervisado.

Unidad 1: Introducción a Machine Learning

Entre las técnicas más empleadas para el análisis supervisado se encuentran

- Técnicas de regresión.
- Técnicas de clasificación.
- Modelos de ensamblado.

En cambio, en los problemas de análisis no supervisado se emplean:

- Técnicas de reducción de la dimensión.
- Clustering.

Unidad 1: Introducción a Machine Learning




Figure: Técnicas de aprendizaje supervisado

Unidad 1: Introducción a Machine Learning




Figure: Técnicas de aprendizaje no supervisado

Unidad 1: Introducción a Machine Learning

El aprendizaje semisupervisado es una rama del machine learning que combina el aprendizaje supervisado y no supervisado mediante el uso de datos etiquetados y no etiquetados para entrenar modelos para tareas de clasificación y regresión.

Por ejemplo, se tienen 30 estudiantes con rendimiento clasificado como alto, medio y bajo, y 200 estudiantes sin clasificación. El modelo usa los 30 casos conocidos y la información estadística del resto para mejorar la clasificación.

Las técnicas empleadas para el aprendizaje automático son

- Self training.
- Co training.
- Label propagation.
- Label Spreading.

Unidad 1: Introducción a machine learning

Otra manera de clasificar los métodos de aprendizaje automático es atendiendo cómo generalizan. La mayoría de los métodos de aprendizaje automático están pensados para realizar predicciones. Esto significa que dado un número de ejemplos que entrenen el método, éste será capaz de hacer buenas predicciones (para generalizar) ejemplos que no haya visto antes.

Ajustar bien los ejemplos de entrenamiento es importante, pero insuficiente. El verdadero objetivo es predecir bien ante nuevos datos. Se pueden clasificar los distintos métodos de aprendizaje automático entre aquellos que están basados en casos o los que están basados en un modelo.

Unidad 1: Introducción a machine learning

Actividad

Clasificar cada situación según el tipo de aprendizaje que representa:

- Una empresa tiene datos históricos de clientes con información sobre edad, ingresos y compras anteriores. También sabe si cada cliente compró o no un producto. Quiere predecir si un nuevo cliente comprará.
- Un supermercado analiza los hábitos de compra de miles de clientes para agruparlos según patrones similares, sin tener etiquetas previas.
- Un hospital usa registros médicos donde se indica si un paciente tuvo o no una enfermedad, para entrenar un modelo que detecte nuevos casos.

Unidad 1: Introducción a machine learning

Actividad

- Una universidad analiza el rendimiento académico de los estudiantes para agruparlos según su desempeño, sin categorías previas.
- Una empresa de transporte posee datos de viajes con información sobre tiempo, distancia y nivel de satisfacción del cliente (bueno/malo). Con ellos busca predecir la satisfacción futura.
- Una red social analiza miles de fotografías para organizarlas por similitud visual sin indicar qué aparece en ellas.

Unidad 1: Introducción a machine learning

El dilema sesgo-varianza

El sesgo

El sesgo estadístico consiste en una distorsión de los resultados en los que el valor calculado difiere del real. El sesgo se puede encontrar tanto en el método como en los datos.

El sesgo en los datos lo podemos encontrar si la muestra obtenida de los datos no es representativa de la población: por muy bueno que sea nuestro modelo no se podrán extraer conclusiones correctas. Por ejemplo, estaríamos ante un problema de sesgo en el muestreo si para estimar la altura de la población general observásemos la altura de las personas que salen de entrenar de un pabellón de baloncesto.

Unidad 1: Introducción a machine learning

El sesgo en el método puede aparecer por el método en sí que se aplique o por la manera en la que se obtienen los parámetros del mismo. En algunas ocasiones, ese sesgo será inevitable, pero tendremos que tratar de reducirlo. En el apartado anterior se ha comentado qué es el sesgo, pero existe otro aspecto a tener en cuenta, que es la varianza del modelo.


Varianza

La varianza del modelo es la variabilidad en los parámetros del modelo ante un conjunto de datos distinto (otra muestra distinta) de la misma población.

En muchas ocasiones, para disminuir esta varianza del modelo, es necesario introducir un sesgo en el mismo. Es lo que se conoce como el dilema o la solución de compromiso sesgo-varianza.

Unidad 1: Introducción a machine learning

La solución de compromiso es importante tener en cuenta que si el modelo con el cual se va a ajustar los datos es demasiado sencillo, se puede producir un infra-ajuste del modelo y obtener un modelo con un sesgo alto. Por el contrario, si acudimos a modelos muy complejos, es posible estar incurriendo en un sobre-ajuste de los datos y, por lo tanto, se obtendrá un modelo con una gran varianza.



Unidad 1: Introducción a machine learning

En el primer panel, se han ajustado los datos mediante un modelo de regresión lineal simple

$$Y = \beta_0 + \beta_1 X$$

que puede presentar un sesgo elevado debido al infraajuste.

En el segundo panel, se han ajustado los datos mediante un modelo de regresión polinómico de grado 2, es decir

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2$$

Por último, en el tercer panel se han ajustado los datos mediante un modelo de regresión polinómico de grado 5, con lo cual, se está obteniendo un sobreajuste del modelo y se tendrá una gran varianza de los parámetros de ajuste frente a nuevos datos.

Unidad 1: Introducción a machine learning

Medida de la bondad del ajuste

Para evaluar la capacidad de un modelo de ajustar un conjunto de datos o de predecir el valor ante un dato no visto es necesario definir una medida de la bondad del ajuste. Según el tipo de problema (regresión o clasificación) y según el tipo de algoritmo empleado se emplearán unas u otras medidas. En los problemas de regresión, una medida habitual para evaluar la bondad del ajuste es la raíz del error cuadrático medio:

$$rmse = \sqrt{\frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{n}}.$$

Unidad 1: Introducción a machine learning

Para evitar los posibles problemas de sobreajuste, es necesario evaluar la bondad del modelo sobre unos datos que no se hayan empleado para la realización del mismo. Existen numerosos métodos para realizar las particiones entre el conjunto de datos de entrenamiento y el conjunto de datos de validación y/o test.

El método más sencillo para construir esta partición consiste en dejar una proporción de los datos para obtener los parámetros del modelo, y luego comprobar con la proporción de datos restante cómo de bueno es ese modelo.

Unidad 1: Introducción a machine learning




Figure: Partición entrenamiento-test básica

Unidad 1: Introducción a machine learning


La ventaja de realizar este método de validación es su sencillez, mientras que el principal inconveniente es que se evalúa un modelo con una potencia predictiva restringida, ya que los datos del dataset de test no aportan información a la realización del método de aprendizaje automático.

Validación cruzada

Para poder incluir información de todos los datos del conjunto de la muestra en la evaluación del modelo es posible realizar la estimación del modelo mediante validación cruzada (CV por sus siglas en inglés). La CV consiste en dividir la muestra en k particiones, entrenar al modelo usando $k - 1$ de las k particiones y después medir la bondad de la predicción en la partición restante.

Unidad 1: Introducción a machine learning

Se realiza este proceso para las k posibles combinaciones de $k - 1$ particiones que existen y se calculan la media de las bondades estimadas



Unidad 1: Introducción a machine learning

Con la CV se consigue incluir toda la información del conjunto de datos a la hora de obtener una estimación del error de generalización del algoritmo de aprendizaje automático través de la media de los errores de los dataset de test para cada una de las comprobaciones.

Un caso especial de validación cruzada es cuando se realizan tantas particiones como número de datos se tienen. Este método se conoce como LOOCV (de las siglas en inglés Leave One Out Cross Validation) y consiste en entrenar el modelo cada vez con todos los datos menos uno y comprobar su validez con el dato restante. Este método tiene como ventajas:

Unidad 1: Introducción a machine learning

- Al realizar una partición para cada dato, desaparece la incertidumbre a la hora de distribuir los datos entre las distintas particiones y no es necesario realizar múltiples repeticiones de la validación cruzada.
- Podemos identificar medidas influyentes: si un resultado de la validación es muy diferente al resto, es posible que el dato correspondiente a esa partición, sea una medida influyente.

Sin embargo, tiene los inconvenientes:

- Puede ser computacionalmente costoso si el número de datos es elevado.
- Puede presentar problemas de sobreajuste, ya que está empleando casi todos los datos $n - 1$ para el entrenamiento del modelo.

Unidad 1: Introducción a machine learning


Validación cruzada anidada

La validación cruzada anidada (NCV por sus siglas en inglés) se utiliza cuando además de querer obtener una estimación del error de generalización es necesario ajustar algún hiperparámetro del algoritmo.

La NCV permite estimar el error de generalización una vez se ha fijado el valor óptimo de los hiperparámetros con un conjunto de datos que no se han empleado para la búsqueda de estos hiperparámetros.

Si se escogieran los hiperparámetros a la vez que se calcula el error, se estaría dando lugar a un resultado del error de generalización demasiado optimista

Unidad 1: Introducción a Machine Learning



Unidad 1: Introducción a Machine Learning

Cálculo del optimismo

Otra manera de obtener una estimación de la bondad del ajuste (o del error de generalización) consiste en:

- Entrenar el modelo o algoritmo con todos los datos disponibles.
- Obtener el error del entrenamiento.

El optimismo se puede definir como la diferencia entre la medida de la bondad del ajuste en el dataset de entrenamiento y la medida de la bondad del ajuste en la generalización. Así pues, el cálculo del optimismo se presenta como una técnica muy útil que permite corregir la bondad del algoritmo, sin perder muestra.