



Clase 2 - Semana 2

Machine Learning

Universidad de Oriente
Facultad de Ingeniería y Arquitectura

30 de enero del 2025

Las variables aleatorias

Las variables aleatorias son funciones que simplifican o permiten el trabajo en probabilidad en un espacio muestral.

- Ejemplo: Tiramos dos monedas al aire, ¿cuál es la probabilidad de obtener dos caras? ¿Y si tiramos la moneda 20 veces?
- Tipos de variables aleatorias: discretas, continuas
- Tipos de variables aleatorias: cuantitativas, cualitativas
- Distribuciones notables: variables aleatorias muy conocidas y utilizadas: normal, uniforme, binomial...

Las variables aleatorias

Las variables aleatorias discretas:

- Toman sus valores en un conjunto numerable.
- Pueden ser cuantitativas o cualitativas.
- Ejemplos de variables discretas cuantitativas: número de accidentes de tráfico en un día, suma del resultado de lanzar dos dados al aire, etc.
- Ejemplos de distribuciones notables discretas (cuantitativas): Bernoulli, binomial, Poisson
- Ejemplos de variables cualitativas: resultado de un test (positivo o negativo), color de un coche, etc.
- Es muy habitual asignar códigos numéricos a variables cualitativas, pero no se pueden tratar como cuantitativas (regresión, cálculo de estadísticos, etc.)

Las variables aleatorias

Las variables aleatorias continuas

- Toman valores en un conjunto no numerable.
- Ejemplos: altura, peso, distancia.
- Ejemplos de distribuciones notables continuas: normal, uniforme, exponencial...


La función de masa o probabilidad en variables aleatorias discretas da la probabilidad de que la función tome cada uno de los valores.

Las variables aleatorias

Ejemplo

Sea $X =$ lanzamiento de un dado, calcular $f(x)$. Se tiene que

$$f(1) = P(X = 1) = \frac{1}{6}, \dots, f(6) = P(X = 6) = \frac{1}{6}$$



Las variables aleatorias

Propiedades de la función masa:

- Es no negativa, es decir:

$$f(x) \geq 0, \quad x \in E_x$$

- La suma de sus valores es uno, es decir


$$\sum_{x \in E_x} f(x) = 1$$

Recordatorio: de estas propiedades se sigue que la probabilidad de un suceso siempre pertenece al intervalo $[0; 1]$

Las variables aleatorias

La función de distribución también caracteriza a las variables aleatorias y representa las probabilidades acumuladas.

Ejemplo: Representar la función de distribución del ejemplo anterior.




Las variables aleatorias

Las propiedades de la función de distribución de una variable discreta son

- Presenta un perfil escalonado, produciéndose un salto en cada uno de los valores definidos de la variable aleatoria.
- La cuantía de cada salto es precisamente la probabilidad en ese punto, obtenida de la función de probabilidad.
- Entre cada dos puntos (de los definidos en la función de probabilidad) no hay cambios de la probabilidad y por lo tanto no se añade nada a la acumulada.
- En los tramos en que sea constante, la probabilidad en esos puntos (función de masa) es cero

Las variables aleatorias

En variables continuas el análogo a la función de masa es la función de densidad.
Por ejemplo la función de densidad de la $N(0, 1)$



Las variables aleatorias

Por lo que

$$P(a < X < b) = \int_a^b f(x) \, dx$$

Propiedades de la función de densidad

- Es no negativa, es decir


$$f(x) > 0, \quad x \in E_x$$

- La suma de sus valores es uno, es decir

$$\int_{-\infty}^{\infty} f(x) \, dx = 1$$

Las variables aleatorias

Las funciones de distribución en el caso continuo también representan las probabilidades acumuladas, aunque su aspecto difiere del caso discreto.



Muestreo

Para estudiar una población en Estadística se toma una muestra. Las razones son:

- La población puede ser infinita.
- Estudiar la población entera puede ser muy costoso aunque sea finita.
- Tomar cada observación puede implicar la destrucción de la muestra

La notación a utilizar es

- N es el tamaño de la población, n el de la muestra.
- μ es la media poblacional, $\bar{x}$ es la media muestral.
- σ es la desviación estándar poblacional, s es la desviación típica muestral.

Muestreo

Tipos de muestro

Aleatorio simple

Todos los elementos tienen la misma probabilidad de ser seleccionados

Estratificado

Se consideran estratos (subpoblaciones) y se muestrea sobre cada uno de ellos

Conglomerados

Se consideran estratos y se toma una muestra que contenga a todos los estratos, de forma que represente a la población.

Inferencia estadística

La inferencia estadística trata de averiguar cosas sobre la población a través de una muestra. Algunos tipos de inferencia son la estimación puntual y los contrastes de hipótesis

Estimación puntual

- A través de un estadístico tratamos de aproximar un parámetro poblacional.
- Ejemplo: $\bar{x}$ para aproximar μ .
- No podemos saber cómo de buena es la aproximación ni hacer afirmaciones o comparaciones entre poblaciones o estratos

Contraste de hipótesis

- Formula una pregunta que se contesta con "sí" o "no" sobre la población y se toma una muestra para responderla.
- Hay dos errores asociados, tipo i y tipo ii

El entorno de Python

- Lenguaje de programación ampliamente utilizado en el ámbito empresarial y académico.
- Librerías que van a utilizarse: numpy, pandas, array, plotnine, scipy, matplotlib, sklearn, math, statsmodels.

Cuestiones de Python que se trabajarán:

- Algunas funciones de las librerías numpy y pandas.
- Manejo de distintas estructuras de datos. Arrays y datasets.
- Introducción a las gráficas (visualización).

El entorno de Python

Jupyter Notebook

El Jupyter Notebook es un entorno interactivo para ejecutar código en el navegador. Es una excelente herramienta para el análisis exploratorio de datos y es ampliamente utilizada por los científicos de datos. Aunque Jupyter Notebook admite muchos lenguajes de programación, solo necesitamos el soporte para Python. Jupyter Notebook facilita la integración de código, texto e imágenes.

Scikit-learn. scikit-learn es un proyecto de código abierto, lo que significa que es libre de usar y distribuir, y que cualquiera puede obtener fácilmente el código fuente para ver qué sucede detrás de escena. El proyecto scikit-learn se desarrolla y mejora constantemente, y cuenta con una comunidad de usuarios muy activa.

El entorno de Python

Numpy

NumPy es uno de los paquetes fundamentales para la computación científica en Python. Contiene funcionalidades para arreglos multidimensionales, funciones matemáticas de alto nivel como operaciones de álgebra lineal, así como generadores de números pseudoaleatorios.

En scikit-learn, el arreglo de NumPy es la estructura de datos fundamental. Scikit-learn recibe los datos en forma de arreglos NumPy. Cualquier dato que se utilice debe convertirse en un arreglo NumPy. La funcionalidad principal de NumPy es la clase `ndarray`, un arreglo multidimensional (de n dimensiones). Todos los elementos del arreglo deben ser del mismo tipo

El entorno de Python

Por ejemplo, si se quiere construir una matriz

$$x = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

se utilizan los comandos.

```
import numpy as np
```

```
x = np.array([[1, 2, 3], [4, 5, 6]])  
print(x)
```

El entorno de Python

Scipy

SciPy es una colección de funciones para la computación científica en Python. Proporciona, entre otras funcionalidades, rutinas avanzadas de álgebra lineal, optimización de funciones matemáticas, procesamiento de señales, funciones matemáticas especiales y distribuciones estadísticas. scikit-learn se apoya en la colección de funciones de SciPy para implementar sus algoritmos.

La parte más importante de SciPy para nosotros es `scipy.sparse`, ya que proporciona matrices dispersas, las cuales son otra forma de representación de datos utilizada en scikit-learn.

El entorno de Python

Matplotlib

Matplotlib es la principal biblioteca para la creación de gráficos científicos en Python. Proporciona funciones para elaborar visualizaciones de calidad para publicaciones, como gráficos de líneas, histogramas, diagramas de dispersión, entre otros. Visualizar los datos y los diferentes aspectos del análisis puede brindar información importante, y utilizaremos matplotlib para todas nuestras visualizaciones. Cuando se trabaja dentro de Jupyter Notebook, es posible mostrar las figuras directamente.

El entorno de Python

Por ejemplo, si se quiere graficar la función $y = \sin(x)$ en el intervalo $[-10, 10]$ se utiliza:

```
import matplotlib.pyplot as plt
```

```
x = np.linspace(-10, 10, 100)
```

```
y = np.sin(x)
```

```
plt.figure()
```

```
plt.plot(x, y)
```

```
plt.show()
```

El entorno de Python

Pandas.

Es una biblioteca de Python para la manipulación y el análisis de datos. Está construida en torno a una estructura de datos llamada DataFrame, la cual está basada en el DataFrame de R. En términos simples, un DataFrame de pandas es una tabla, similar a una hoja de cálculo de Excel. pandas proporciona una amplia gama de métodos para modificar y operar sobre esta tabla; en particular, permite realizar consultas y uniones de tablas al estilo SQL.

A diferencia de NumPy, que requiere que todos los elementos de un arreglo sean del mismo tipo, pandas permite que cada columna tenga un tipo diferente (por ejemplo, enteros, fechas, números de punto flotante y cadenas de texto).

El entorno de Python

Si se quiere construir el siguiente data frame:

Edad	Ubicación	Nombre
24	New York	John
13	Paris	Anna
53	Berlin	Peter
33	Londres	Linda

```
import pandas as pd
```

```
data = pd.DataFrame()
```

```
data["Edad"] = [24,13,53,55]
```

```
data["Ubicación"] = ["New York", "Paris", "Berlin", "Londres"]
```

```
data["Nombre"] = ["John", "Anna", "Peter", "Linda"]
```

Ejemplo

Ejemplo 1

Obtener con python las muestras de las siguientes distribuciones:

- 10 valores de la uniforme $[0, 1)$.
- 5 días de la semana, con repetición.
- 8 valores de tirar 2 dados.

Ejemplo 2

La altura de una población se distribuye como una normal de media 170 y desviación típica 5. Se pide:

- Obtener las siguientes muestras de la población y representar las distribuciones obtenidas gráficamente:
 - 10 valores de la normal ($\mu = 170, \sigma = 5$)
 - 100 valores de la normal ($\mu = 170, \sigma = 5$)
 - 10000 valores de la normal ($\mu = 170, \sigma = 5$)

Ejemplo

...

- Obtener el valor teórico de la distribución normal ($\mu = 170$, $\sigma = 5$)
- Calcular la probabilidad de que una persona mida menos de 160 cm o más de 195 cm.

Ejemplo 3

Latveria y Symkaria son dos poblaciones vecinas. Los hombres y mujeres de Latveria miden de media 175 cm y 169 cm respectivamente y tienen para ámbas distribuciones una desviación típica de 6 cm. En Symkaria, en cambio, las mujeres miden de media 173 cm y los hombres 171. La desviación típica en la altura de las mujeres de Symkaria es de 7 cm y en la de los hombres de 3 cm

- Con estos datos, conformar un dataframe que contenga las medidas de 2000 hombres y de 2000 mujeres de cada población. Calcular la media y la desviación típica de la población.

Ejemplos

...

- Realiza un muestreo estratificado con 4 estratos y $n = 100/\text{estrato}$. Calcula la media y desviación típica de cada estrato.
- Realiza un muestreo por conglomerados con 2 conglomerados y $n = 200/\text{conglomerado}$. Calcula la media y desviación típica de cada conglomerado.