



Clase 3 - Semana 3

Machine Learning

Universidad de Oriente
Facultad de Ingeniería y Arquitectura

06 de febrero del 2025

Estadística robusta

En este tema se explicará en qué consiste la estadística robusta, cuál es la diferencia entre métodos paramétricos y no paramétricos, y qué técnicas permiten tratar con datos atípicos, muy comunes en el análisis estadístico de datos.

La estadística clásica se asienta sobre la base de que los métodos estadísticos cumplen una serie de supuestos que permiten dar fiabilidad a los resultados obtenidos por dichos modelos.

Estos supuestos son, entre otros, la normalidad de los datos, la homocedasticidad de la muestra, la independencia de los datos y el tamaño suficiente de muestra.

Estadística robusta

No obstante, en muchas ocasiones, estos supuestos o bien no se pueden cumplir, o bien se obvian por parte de los investigadores, dando lugar a resultados que no son del todo fiables. Esto ocurre, por ejemplo, cuando la muestra presenta valores atípicos que impiden la normalidad de los datos, y a su vez sesgan los parámetros de la misma en que se basan los modelos estadísticos. Supongamos las siguientes distribuciones que hacen referencia a las notas de dos alumnos distintos:

$$A = \{6, 6, 7, 5, 6\}$$

$$B = \{8, 7, 8, 7, 0\}$$

Aunque tengan la misma media ($\mu = 5$), no son iguales las distribuciones de las notas.

Estadística robusta

El uso de estadística robusta proporciona técnicas que permiten establecer conclusiones adecuadas a pesar de no cumplir con todos los supuestos estadísticos anteriores. Su nombre hace referencia a que no se ve afectada por las anomalías de las muestras, siendo, por tanto, más “robusta”.

En estadística se suele hacer referencia a dos tipos de métodos según los supuestos que deben cumplir las poblaciones que se muestrean: los métodos paramétricos y los métodos no paramétricos.

Métodos paramétricos

Los métodos paramétricos forman parte de la estadística paramétrica, la cual es una rama de la estadística inferencial que comprende los procedimientos estadísticos y de decisión que están basados en distribuciones conocidas. Estas son determinadas usando un número finito de parámetros: el estimador clásico de localización, empleado en los métodos paramétricos es la media, mientras que el estimador clásico de dispersión es la desviación típica.

Métodos paramétricos

Los métodos paramétricos forman parte de la Estadística clásica se utilizan cuando:

- Partimos de una distribución conocida en la que uno o más parámetros son desconocidos
- Ejemplo: asumimos que la estatura de la población sigue una distribución normal, con media y desviación típica desconocidas.
- La media y la desviación típica son los parámetros que deseamos conocer: estimadores.
- Condiciones que se asumen: observaciones independientes, varianzas poblacionales similares (homocedasticidad), relación lineal entre variables, distribución normal...

Son ampliamente utilizados porque pueden obtenerse tests uniformemente de máxima potencia y hay gran cantidad de pruebas

Métodos paramétricos

La normalidad


La normalidad es una de las hipótesis más frecuentes en estadística paramétrica. Este supuesto hace referencia a que las variables o las muestras utilizadas de las mismas deben seguir una distribución normal de los datos.

Para comprobar si la distribución teórica se ajusta a una distribución normal, se realizan diferentes tipos de pruebas. Las más conocidas son la Prueba de Kolmogorov-Smirnov, utilizada con tamaños de muestra grandes, y la Prueba de Shapiro-Wilk, válida para tamaños de muestra no muy grandes ($n < 5000$).


Métodos paramétricos

Por otro lado, también es adecuado analizar la distribución de los valores mediante técnicas de visualización, lo que permitirá comprobar la existencia de datos anómalos (también llamados datos aberrantes u outliers) y comprobar si se trata de posibles errores. Una de las opciones es utilizar un gráfico $q - q$ ($q - q$ plot) donde se representan los valores reales de los percentiles de la distribución frente a los teóricos de una distribución normal. Cuanto más se aproximen los puntos a la recta, más similitud se tendrá con la distribución normal

Métodos paramétricos



Métodos paramétricos




Métodos paramétricos

Homocedasticidad

La homocedasticidad, o igualdad de varianzas, hace referencia a que la varianza de los errores es constante a lo largo del tiempo. Por tanto, será importante cuando tengamos que enfrentarnos a problemas de regresión o series temporales, ya que cuando se verifica esta hipótesis el modelo resultante es mucho más sencillo.

En el caso de que los errores presenten una varianza no constante, estaríamos ante heterocedasticidad, lo cual impide la estabilidad de los datos y la aplicación de métodos estadísticos clásicos. De nuevo, la visualización gráfica puede resultar muy útil. Para ello, se puede realizar un diagrama de dispersión de los residuos

Métodos paramétricos



Métodos no paramétricos

Una prueba no paramétrica es una prueba de hipótesis que no requiere que la distribución de la población sea caracterizada por ciertos parámetros. Las pruebas no paramétricas no parten de este supuesto, de modo que son útiles cuando los datos son no normales, o cuando el tamaño muestral es demasiado pequeño, o cuando hay una presencia considerable de outliers o cuando sospechamos que los datos de la muestra pueden provenir de más de una población.

Métodos no paramétricos

A continuación, se muestra la correspondencia entre las distintas pruebas paramétricas y no paramétricas

Pruebas paramétricas y no paramétricas		
Tipo de prueba	Paramétrica	No Paramétrica
Describir una muestra	Media y varianza	Mediana, rango intercuartil
Comparar una muestra con un valor	Test t de una muestra (media)	Prueba Wilcoxon (mediana)
Comparar dos muestras independientes	Test t de igualdad de medias	Prueba Mann-Whitney (mediana)
Comparar dos muestras apareadas	Test t de igualdad de medias apareadas	Prueba Wilcoxon (mediana)
Para n muestras	ANOVA	Prueba Kruskal-Wallis

Estimadores robustos

Estimadores de localización.

Como se ha comentado anteriormente, la media es el estadístico de localización por excelencia. Sin embargo, existe otros estimadores de localización, que son robustos entre los que destaca la mediana.

- Mediana: es el valor de la variable que divide a la distribución en dos partes iguales conteniendo cada una de ellas el 50 % de las observaciones. La mediana muestral resulta mucho menos afectada que la media muestral por la existencia de valores atípicos.

Estimadores robustos

Además de la mediana muestral, existen otros estimadores alternativos a la media que son robustos frente a la existencia de outliers. Entre ellos, las α -medias recortadas, las cuales eliminan un porcentaje α de las observaciones muestrales en cada extremo.

- Media recortada: Consiste en calcular la media aritmética sobre un subconjunto central del conjunto de datos, no considerándose una determinada proporción α por cada extremo.

Por ejemplo, una media recortada al 40 % ($\alpha = 0.4$) en una secuencia de 10 datos implica no tener en cuenta ni los 4 valores menores ni los 4 valores mayores. Es interesante hacer notar que la media recortada al 0 % es la media aritmética, y que la media recortada al 25 % ($\alpha = 0.25$) se la denomina centrimedia.

Estimadores robustos

La media recortada queda definida por la proporción de casos, α , que son excluidos desde cada extremo de la muestra ordenada. Una vez que se han eliminado los valores indicados de cada extremo, se calcula el promedio de los valores restantes.

- Si α es un múltiplo de $1/n$, se eliminan de cada extremo un número entero de valores $[\alpha \cdot n]$ y la media recortada es el promedio de los $s = n(1 - 2\alpha)$ valores restantes, que se calcula mediante la fórmula

$$m(\alpha) = \frac{\sum X_i}{s}$$

- Si α no es múltiplo de $1/n$, se elimina el menor número entero de valores $[\alpha \cdot n]$ más cercano a $\alpha \cdot n$ de cada extremo, y al mayor y menor valor restante se le pondera con $p = 1 + [\alpha \cdot n] - \alpha \cdot n$

Estimadores robustos

Para calcular la media ponderada recortada, en este caso, se usa la fórmula

$$m(\alpha) = \frac{pX_1 + X_2 + \cdots + X_{s-1} + pX_s}{n(1 - 2\alpha)}$$

Esto es así porque para calcular la media recortada se eliminan las puntuaciones más alejadas del núcleo central de la distribución por ambos lados, y se trabaja solo con el centro de las puntuaciones, así la media no se ve afectada por las puntuaciones extremas.

Estimadores robustos

- Media winsorizada: esta media sustituye los casos excluidos del análisis por el último valor, en cada extremo, que sí forme parte del análisis. Cuando se cambian estos valores, se calcula el promedio de las puntuaciones. Se calculan usando la fórmula:

$$W(\alpha) = \frac{\sum_i^n X_i}{n}$$

donde α es la proporción de casos excluidos por cada extremo

Estimadores robustos

- **Trimedia:** Es un índice de tendencia central que consiste en calcular una media aritmética ponderada de tres medidas: el primer cuartil, la mediana (con peso doble) y el tercer cuartil.

$$\text{Trimedia} = \frac{\text{cuartil } 1 + 2\text{mediana} + \text{cuartil } 3}{4}$$

Como ya se ha comentado anteriormente, en general las estimaciones robustas (mediana, media recortada, media winsorizada y trimedia) son menos eficientes que los estimadores clásicos, como la media muestral, cuando las observaciones muestrales proceden de distribuciones normales.

Estimadores de dispersión

Al igual que existen alternativas robustas a la media (el cual es un estimador de localización), también existen alternativas robustas a la desviación típica como estimador de escala.

- MAD (o MEDA): Entre las más habituales se encuentra la desviación absoluta mediana, definida como la mediana de las desviaciones en valor absoluto respecto a la mediana (Me), es decir

$$MAD = \text{Mediana}\{|i - M|\}, \quad i = 1, 2, \dots, n$$

- Rango intercuartílico: Otro estimador de dispersión robusto es el rango intercuartílico definido como la distancia entre las cuales está el 50 % central de los valores muestrales, es decir:

$$RIQ = [\text{Percentil } 0.25, \text{Percentil } 0.75]$$

Ejemplos

Ejemplo 1

- Comprobar la normalidad a una muestra obtenida mediante el muestreo aleatorio de una distribución normal con media $\mu = 0.05$ y desviación típica $\sigma = 0.9$ y $n = 1000$.
- Comprueba la normalidad a una muestra obtenida mediante el muestreo aleatorio de una distribución normal con media $\mu = 0.05$ y desviación típica $\sigma = 0.9$ y $n = 10000$.

Ejemplo 2

Simular lo siguiente:

- Una muestra ε de $n = 500$ de una distribución normal con media $\mu = 0$ y desviación típica $\sigma = 1$.
- Una muestra x de $n = 500$ de una distribución uniforme $[0, 200]$

Ejemplos

...

Construir las muestras $Y1$ e $Y2$ que sean igual a:

$$Y1 = 100 + 200x + \varepsilon x$$

$$Y2 = 100 + 200x + \varepsilon$$

- Obtén un modelo de regresión lineal $Y = \beta_0 + \beta_1 x$ para $Y1$ e $Y2$ y representa gráficamente los residuos de los modelos
- Realiza la prueba de Breusch-Pagan para cada uno de los modelos

Ejemplos

Ejemplo 3

Se tiene la siguiente muestra $X = \{4, 3, 11, 5, 4, 50, 6, 8, 7, 9\}$, en el que el valor 50 es un outlier.

- Calcular la media recortada de la muestra al 20 %, al 10 % y calcula la centrímedia.
- Calcular la media winsorizada al 20 %.
- Calcular la trimedia.
- Comparar los valores obtenidos en los apartados a), b) y c) con la media muestral.
- Calcular el MAD y compararlo con la desviación típica.