

Universidad de Oriente	
Machine Learning	Clase 08 - Ejemplo 3 - Regresión lineal múltiple

Ventas en Publicidad

Crear y evaluar un modelo de regresión lineal múltiple para predecir las ventas con datos simulados de una empresa dependiendo de las inversiones realizadas en publicidad.

- Analizar la relación entre cada variable predictora y la variable Sales mediante gráficos de dispersión.
- Construir el modelo de regresión lineal múltiple utilizando las variables TV, Radio, Newspaper y Web.
- Estimar los coeficientes del modelo e interpretar su significado.
- Evaluar el ajuste del modelo utilizando las siguientes métricas:
 - Coeficiente de determinación R^2 .
 - Error cuadrático medio (MSE).
 - Raíz del error cuadrático medio (RMSE).
- Analizar la significancia estadística de las variables explicativas.
- Comparar gráficamente los valores reales contra los predichos
- Evaluar la posible multicolinealidad entre las variables predictoras mediante el Factor de Inflación de la Varianza (VIF) y los autovalores de la matriz de correlación
- Se desea estimar el volumen de ventas. Para ello, se consideran los siguientes valores: inversión en TV de 296.4, en Radio de 49.6, en Newspaper de 114.0 y en Web de 358.247042

```
In [13]: import pandas as pd
import numpy as np
import statsmodels.api as sm
import seaborn as sns # Gráficos
from sklearn import linear_model
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures # Polinomial
from scipy import stats
import matplotlib.pyplot as plt
from sklearn.metrics import mean_squared_error, r2_score
from statsmodels.stats.outliers_influence import variance_inflation_factor
```

```
In [15]: datos = pd.read_csv("https://raw.githubusercontent.com/rpizarrog/Analisis-Inteli")
```

```
In [17]: datos
```

Out[17]:

	Unnamed: 0	X	TV	Radio	Newspaper	Web	Sales
0	1	1	230.1	37.8	69.2	306.634752	22.1
1	2	2	44.5	39.3	45.1	302.653070	10.4
2	3	3	17.2	45.9	69.3	49.498908	9.3
3	4	4	151.5	41.3	58.5	257.816893	18.5
4	5	5	180.8	10.8	58.4	195.660076	12.9
...	...	...	...	...	...	...	...
195	196	196	38.2	3.7	13.8	248.841073	7.6
196	197	197	94.2	4.9	8.1	118.041856	9.7
197	198	198	177.0	9.3	6.4	213.274671	12.8
198	199	199	283.6	42.0	66.2	237.498063	25.5
199	200	200	232.1	8.6	8.7	151.990733	13.4

200 rows × 7 columns

In [19]: `#Eliminar columnas "Unnamed:0" y "X"`
`data = datos.drop(["Unnamed: 0", "X"], axis=1)`
`data`

Out[19]:

	TV	Radio	Newspaper	Web	Sales
0	230.1	37.8	69.2	306.634752	22.1
1	44.5	39.3	45.1	302.653070	10.4
2	17.2	45.9	69.3	49.498908	9.3
3	151.5	41.3	58.5	257.816893	18.5
4	180.8	10.8	58.4	195.660076	12.9
...	...	...	...	...	...
195	38.2	3.7	13.8	248.841073	7.6
196	94.2	4.9	8.1	118.041856	9.7
197	177.0	9.3	6.4	213.274671	12.8
198	283.6	42.0	66.2	237.498063	25.5
199	232.1	8.6	8.7	151.990733	13.4

200 rows × 5 columns

In [21]: `data.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 5 columns):
#   Column      Non-Null Count  Dtype
---  -
0   TV           200 non-null    float64
1   Radio        200 non-null    float64
2   Newspaper    200 non-null    float64
3   Web          200 non-null    float64
4   Sales        200 non-null    float64
dtypes: float64(5)
memory usage: 7.9 KB
```

Se describen las variables independientes: *TV*, *Radio*, *Newspaper* y *Web*.

Se describe la variable dependiente *Sales*: significa el volumen de ventas del producto correspondiente.

Para un solo producto en un mercado determinado, el costo de la publicidad, en miles, de las variables independientes:

-**TV**: costos de publicidad invertidos en TV.

-**Radio**: costos de publicidad invertidos en radio.

-**Periódico**: costos de publicidad invertidos en medios periodísticos.

-**Web**: costos de publicidad invertidos en páginas web.

In [23]: `data.describe()`

Out[23]:

	TV	Radio	Newspaper	Web	Sales
count	200.000000	200.000000	200.000000	200.000000	200.000000
mean	147.042500	23.264000	30.554000	159.587355	14.022500
std	85.854236	14.846809	21.778621	76.815266	5.217457
min	0.700000	0.000000	0.300000	4.308085	1.600000
25%	74.375000	9.975000	12.750000	99.048767	10.375000
50%	149.750000	22.900000	25.750000	156.862154	12.900000
75%	218.825000	36.525000	45.100000	212.311848	17.400000
max	296.400000	49.600000	114.000000	358.247042	27.000000

In [25]: `data.head()`

Out[25]:

	TV	Radio	Newspaper	Web	Sales
0	230.1	37.8	69.2	306.634752	22.1
1	44.5	39.3	45.1	302.653070	10.4
2	17.2	45.9	69.3	49.498908	9.3
3	151.5	41.3	58.5	257.816893	18.5
4	180.8	10.8	58.4	195.660076	12.9

In [27]: `data.tail()`

Out[27]:

	TV	Radio	Newspaper	Web	Sales
195	38.2	3.7	13.8	248.841073	7.6
196	94.2	4.9	8.1	118.041856	9.7
197	177.0	9.3	6.4	213.274671	12.8
198	283.6	42.0	66.2	237.498063	25.5
199	232.1	8.6	8.7	151.990733	13.4

In [29]: `#crear matriz de correlación`
`corr = data.corr()`
`corr.style.background_gradient()`

Out[29]:

	TV	Radio	Newspaper	Web	Sales
TV	1.000000	0.054809	0.056648	0.012576	0.782224
Radio	0.054809	1.000000	0.354104	-0.122673	0.576223
Newspaper	0.056648	0.354104	1.000000	-0.057759	0.228299
Web	0.012576	-0.122673	-0.057759	1.000000	0.002108
Sales	0.782224	0.576223	0.228299	0.002108	1.000000


a) En esta sección se analiza la relación existente entre cada una de las variables predictoras (TV , Radio , Newspaper y Web) y la variable respuesta Sales mediante gráficos de dispersión.

Los gráficos de dispersión permiten visualizar la posible relación entre dos variables cuantitativas y observar patrones como tendencias lineales, dispersión de los datos o posibles valores atípicos. Este análisis exploratorio es útil para identificar qué variables podrían tener mayor influencia en el volumen de ventas y evaluar preliminarmente si un modelo de regresión lineal es adecuado para describir dichas relaciones.

A partir de estas representaciones gráficas se puede evaluar visualmente la fuerza y dirección de la relación entre cada inversión publicitaria y las ventas.

In [32]: `sns.pairplot(data, x_vars=['TV', 'Radio', 'Newspaper', 'Web'], y_vars='Sales', h`
`plt.xlabel("Web")`

```
plt.ylabel("Sales")
plt.show()
```



Se muestra las relaciones lineales entre las variables independientes con respecto a *Sales*.

Es posible estimar visualmente que la variable *Newspaper* tal vez tenga poco impacto en las *Sales*, esto por la alta dispersión de los datos. Sin embargo participará en el modelo de regresión lineal múltiple.

Se observa también que la variable *Web* tiene poca correlación lineal con la variable *Sales*.

b) En esta sección se construye un modelo de regresión lineal múltiple con el objetivo de analizar cómo las inversiones en distintos medios publicitarios influyen en el volumen de ventas del producto.

Para ello, se consideran como variables predictoras las inversiones en publicidad en televisión (*TV*), radio (*Radio*), periódicos (*Newspaper*) y plataformas web (*Web*). La variable respuesta es *Sales* , que representa el volumen de ventas.

```
In [36]: # creamos un dataset con las variables predictoras
X_independientes = data.drop("Sales", axis=1)

X_independientes.head()
```

```
Out[36]:
```

	TV	Radio	Newspaper	Web
0	230.1	37.8	69.2	306.634752
1	44.5	39.3	45.1	302.653070
2	17.2	45.9	69.3	49.498908
3	151.5	41.3	58.5	257.816893
4	180.8	10.8	58.4	195.660076

```
In [38]: # aislamos la variable respuesta
y_dependiente = data["Sales"].copy()

y_dependiente
```

```
Out[38]: 0      22.1
         1      10.4
         2       9.3
         3      18.5
         4      12.9
         ...
        195     7.6
        196     9.7
        197    12.8
        198    25.5
        199    13.4
        Name: Sales, Length: 200, dtype: float64
```

```
In [40]: #se construye el modelo de regresión
modelo_rm = LinearRegression()

modelo_rm.fit(X_independientes, y_dependiente)
```

```
Out[40]: ▼ LinearRegression ⓘ ?
         LinearRegression()
```

```
In [42]: # obtener coeficientes del modelo
         # intercepto
print("El intercepto es %s" %modelo_rm.intercept_)
```

El intercepto es 2.2442221995917713

```
In [44]: # coeficientes de regresión
pd.DataFrame({"Variables":X_independientes.columns, "Coeficientes": modelo_rm.coef_})

#print(modelo_rm.coef_)
```

```
Out[44]:
```

	Variables	Coeficientes
0	TV	0.045693
1	Radio	0.190975
2	Newspaper	-0.000794
3	Web	0.004016

Predicción:

$Y = b_0 + b_1 \cdot x_1 + b_2 \cdot x_2 + b_3 \cdot x_3 + b_4 \cdot x_4$

Predicción de Sales:

\$\$

$\text{Sales} = b_0 + b_1 \cdot \text{TV} + b_2 \cdot \text{Radio} + b_3 \cdot \text{Newspaper} + b_4 \cdot \text{Web}$

\$\$

c) Evaluación del ajuste del modelo

Una vez estimado el modelo de regresión lineal múltiple, se evaluará su capacidad para explicar y predecir el comportamiento de la variable Sales. Para ello, se utilizarán las siguientes métricas de desempeño:

- Coeficiente de determinación (R^2): mide la proporción de la variabilidad de la variable dependiente que es explicada por el modelo. Valores cercanos a 1 indican un mejor ajuste.
- Error cuadrático medio (MSE): representa el promedio de los cuadrados de los errores entre los valores reales y los valores predichos por el modelo. Permite cuantificar la magnitud del error del modelo.
- Raíz del error cuadrático medio (RMSE): corresponde a la raíz cuadrada del MSE y se interpreta en las mismas unidades que la variable dependiente, lo que facilita la comprensión del error promedio de las predicciones.

```
In [48]: #Cálculo de  $R^2$ 
y_pred = modelo_rm.predict(X_independientes)
r_2 = r2_score(y_dependiente, y_pred)

#Cálculo de MSE
MSE = mean_squared_error(y_dependiente, y_pred)

#Cálculo de RMSE
RMSE = np.sqrt(MSE)

print("El coeficiente de determinación es %.6f" %r_2)
print("El error cuadrático medio es %.6f" %MSE)
print("La raíz cuadrada del error cuadrático medio es %.6f" %RMSE)
```

El coeficiente de determinación es 0.900652

El error cuadrático medio es 2.690922

La raíz cuadrada del error cuadrático medio es 1.640403

d) Una vez estimado el modelo de regresión lineal múltiple, se analizará la significancia estadística de las variables explicativas con el objetivo de determinar si cada una de ellas tiene un efecto relevante sobre la variable dependiente Sales.

Para ello, se examinarán los estadísticos t y los valores p (p-values) asociados a los coeficientes del modelo. Estos indicadores permiten evaluar la hipótesis:

```
In [50]: # Definir matriz de diseño y variable respuesta
X = X_independientes
y = y_dependiente

#Añadir intercepto
X2 = sm.add_constant(X)

#Ajustar el modelo
est = sm.OLS(y, X2)

#Ver ajuste
est2 = est.fit()
print(est2.summary())
```

OLS Regression Results

Dep. Variable:	Sales	R-squared:	0.901
Model:	OLS	Adj. R-squared:	0.899
Method:	Least Squares	F-statistic:	441.9
Date:	Fri, 20 Mar 2026	Prob (F-statistic):	1.48e-96
Time:	09:43:19	Log-Likelihood:	-382.78
No. Observations:	200	AIC:	775.6
Df Residuals:	195	BIC:	792.0
Df Model:	4		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	2.2442	0.407	5.509	0.000	1.441	3.048
TV	0.0457	0.001	33.228	0.000	0.043	0.048
Radio	0.1910	0.009	22.364	0.000	0.174	0.208
Newspaper	-0.0008	0.006	-0.137	0.891	-0.012	0.011
Web	0.0040	0.002	2.599	0.010	0.001	0.007

Omnibus:	61.291	Durbin-Watson:	2.071
Prob(Omnibus):	0.000	Jarque-Bera (JB):	166.901
Skew:	-1.307	Prob(JB):	5.73e-37
Kurtosis:	6.632	Cond. No.	814.

Notes:


[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

En cuanto a la significancia individual de las variables, se observa que TV, Radio y Web presentan valores p menores a 0.05, por lo que son estadísticamente significativas y contribuyen a explicar la variable Sales. En particular, TV y Radio tienen un impacto positivo importante, mientras que Web también influye positivamente, aunque en menor magnitud.

Por otro lado, la variable Newspaper presenta un valor $p = 0.891$, mayor a 0.05, lo que indica que no es estadísticamente significativa dentro del modelo y no contribuye de manera relevante a explicar las ventas.

Para evaluar el desempeño del modelo, se realiza una comparación gráfica entre los valores reales y los valores predichos de la variable Sales. Esta comparación se lleva a cabo mediante un gráfico de dispersión, donde en el eje horizontal se representan los valores reales y en el eje vertical los valores estimados por el modelo.

```
In [54]: plt.figure()
plt.scatter(y_dependiente, y_pred)
plt.xlabel("Valores reales")
plt.ylabel("Valores predichos")
plt.plot([np.min(X_independientes), np.max(y_dependiente)], [np.min(X_independien
color = 'red', linewidth = 3)
plt.show()
```

La multicolinealidad entre las variables predictoras se evalúa mediante el Factor de Inflación de la Varianza (VIF) y el análisis de los autovalores de la matriz de correlación.

Por un lado, el VIF permite medir el grado de correlación lineal entre cada variable independiente y el resto. Valores de VIF cercanos a 1 indican ausencia de multicolinealidad, mientras que valores superiores a 5 sugieren correlación moderada y valores mayores a 10 evidencian problemas severos. En este caso, se identifican variables con VIF elevados, lo que indica la presencia de multicolinealidad en el modelo y posibles dificultades en la estabilidad de los coeficientes estimados.

Por otro lado, el análisis de los autovalores de la matriz de correlación permite evaluar la dependencia lineal global entre las variables. Autovalores cercanos a cero indican la existencia de combinaciones lineales entre variables colinealidad. Sin embargo, si los autovalores se mantienen alejados de cero, se puede inferir que no existe una multicolinealidad severa a nivel global.

En conjunto, ambos métodos permiten complementar el diagnóstico: mientras el VIF detecta problemas de colinealidad de forma individual entre variables, los autovalores analizan la estructura global del conjunto de datos.

```
In [56]: # Variance Inflation Factor
# Crear dataframe para aplicar VIF
VIF = pd.DataFrame()
VIF["variable"] = X_independientes.columns

# Aplicar el método
VIF["VIF"] = [variance_inflation_factor(X_independientes.values, i) for i in ran
```

VIF

Out[56]:

	variable	VIF
0	TV	3.172879
1	Radio	3.427062
2	Newspaper	3.191014
3	Web	3.088313

Los valores del Factor de Inflación de la Varianza (VIF) para todas las variables independientes se encuentran en el rango de 3 a 3.5, lo que indica la presencia de una correlación moderada entre ellas, pero no evidencia de multicolinealidad severa. Por tanto, se concluye que el modelo no presenta problemas significativos de multicolinealidad.

In [58]: *#Obtención de Los autovalores de la matriz de correlación*

```
corr_ind = X_independientes.corr()
av, v = np.linalg.eig(corr_ind)
AV = pd.DataFrame()
AV["Variable"] = X_independientes.columns
AV["Autovalor"] = av

AV
```

Out[58]:

	Variable	Autovalor
0	TV	1.408008
1	Radio	1.013760
2	Newspaper	0.938592
3	Web	0.639639

El análisis de los autovalores de la matriz de correlación muestra que ninguno de ellos es cercano a cero, siendo el menor de 0.6396. Esto sugiere que no existen relaciones lineales fuertes entre las variables independientes.

Para resolver el problema, se utiliza el modelo de regresión lineal previamente ajustado, el cual relaciona las variables de inversión en publicidad con el volumen de ventas. En primer lugar, se organiza el vector de entrada con los nuevos valores de inversión en el mismo orden en que fueron definidas las variables independientes del modelo TV, Radio, Newspaper y Web

In [60]: *#Vector con los valores de las variables independientes*

```
pred_x = np.array([296.4, 49.6, 114, 358.247042])

prediccion = modelo_rm.predict(pred_x.reshape(1, -1))

print("El volumen de ventas que se espera es %s" %prediccion[0])
```

El volumen de ventas que se espera es 26.608175004034084

```
C:\Users\USER\anaconda3\Lib\site-packages\sklearn\base.py:493: UserWarning: X does not have valid feature names, but LinearRegression was fitted with feature names
  warnings.warn(
```

Fin

In []: