



Clase 10 - Semana 10

Machine Learning

Universidad de Oriente
Facultad de Ingeniería y Arquitectura

27 de marzo del 2026

Regresión de Lasso, Ridge y red elástica

Cuando se hace regresión lineal (simple o múltiple) podemos encontrarnos con varios problemas:

- Modelo no lineal. Solución: buscar otro tipo de ajuste.
- Presencia de outliers. Posible solución: mínimos cuadrados recortados.
- Colinealidad. Posible solución: regresión penalizada


Regresión de Lasso, Ridge y red elástica

La regresión por mínimos cuadrados recortados consiste en hacer una regresión por mínimos cuadrados ordinarios sobre todos los subconjuntos de la muestra con h elementos y quedarnos con el que tenga menor error.

El valor de h es el valor para el número máximo de outliers, de tal manera que $n/2 \leq h < n$. El valor de h se estima por conocimiento previo que se tenga sobre la muestra o población.

El problema es que el proceso es computacionalmente costoso, ya que se necesitarían un total de $\binom{n}{h}$ combinaciones y es en general un número muy grande.

Regresión de Lasso, Ridge y red elástica



Regresión penalizada

Anteriormente se han descrito estrategias para realizar la selección de variables. Estos métodos, en algunas ocasiones, no son lo suficientemente consistentes para poder realizar la selección de variables y se han desarrollado diversas alternativas. Una de ellas es ajustar el modelo mediante una regresión penalizada.

Este método es muy útil cuando se tienen variables predictoras que presentan problemas de colinealidad o cuando tenemos muchas variables predictoras en comparación con el número de observaciones.

Regresión penalizada

La regresión penalizada es similar a la regresión por mínimos cuadrados, pero añadiendo una restricción sobre el tamaño de los coeficientes de regresión. Dentro de la regresión penalizada, se pueden distinguir dos tipos distintos atendiendo a la manera en la que están definidas estas restricciones: la regresión de tipo Ridge y la regresión de tipo LASSO. Por último, se pueden combinar ambas restricciones dando lugar a lo que se conoce como la Red Elástica

Regresión Ridge

La regresión Ridge consiste en añadir una penalización de tipo cuadrático a la estimación de los coeficientes β , ya sea cuando se obtienen por mínimos cuadrados o por otros métodos, como el de máxima verosimilitud.

En la regresión Ridge se busca minimizar el error cuadrático medio, pero con la restricción de que

$$\sum \beta_i^2 < s$$


donde s es conocido como el parámetro de ajuste. Es interesante apuntar que en la regresión Ridge no se llega a producir una selección de variables, sino que los distintos coeficientes se van encogiendo a medida que el valor del parámetro de ajuste s disminuye y, en consecuencia, la restricción aumenta

Regresión Ridge

Aunque no realiza selección de variables, la regresión Ridge presenta dos grandes ventajas frente a la regresión por mínimos cuadrados ordinarios.

- La primera de las ventajas consiste en que se reduce la varianza de los modelos para distintas posibles muestras de la población, a costa de aumentar el sesgo. Pero, en el caso en el que se tienen muchas variables predictoras, suele mejorar los resultados en el cómputo global.
- La segunda ventaja es que aunque puede aumentar el sesgo ligeramente, disminuye la varianza global y, por tanto, el error cuadrático medio. Muy útil si cambia la muestra (entrenamiento-test)

Regresión Ridge



Regresión LASSO

La regresión de tipo LASSO (siglas en inglés de Least Absolute Shrinkage and Selection Operator) es similar a la regresión Ridge, pero con la restricción sobre los coeficientes β , es decir que es de la forma

$$\sum |\beta_i| < s$$

La regresión LASSO, tiene la ventaja de que, al contrario de lo que ocurre con la regresión Ridge, con un s suficientemente pequeño se consigue que los coeficientes se encojan hasta 0 y, por lo tanto, es posible hacer selección de variables.

Regresión LASSO

En cambio, el mayor inconveniente de este tipo de regresión lo encontramos cuando entre las variables predictoras algunas de ellas están fuertemente correlacionadas, ya que en estos casos la regresión de tipo LASSO tiende a seleccionar únicamente a una de estas variables y a descartar el resto, aumentando la varianza del modelo.

Red elástica

Una vez que ya se han definido las regresiones LASSO y Ridge, se puede definir la regresión de tipo Red Elástica. Ésta se obtiene como la regresión en la que intervienen al mismo tiempo las penalizaciones de tipo LASSO y de tipo Ridge, siendo determinado el peso de cada una de ellas mediante el hiperparámetro de ajuste r , tal y como se define

$$(1 - r) \sum \beta_i^2 + r \sum |\beta_i| < s,$$

donde r tiene un valor entre 0 y 1 (Con $r = 1$ se obtiene la regresión de LASSO y con $r = 0$ se obtiene la regresión de Ridge).


Red elástica

La elección del hiperparámetro r no es trivial y debe escogerse cuidadosamente según las características del problema y según el tipo de modelo que se desea obtener. En algunas ocasiones se podrá prefijar de antemano este hiperparámetro y en otras ocasiones será más adecuado ajustarlo mediante técnicas de validación.

- Hacer una partición de la muestra.
- Para un valor de r , determinar el valor de α que minimice el error para diferentes valores de α .
- Repetir esto para obtener la función de densidad. El valor de α así obtenido minimiza el error.
- Repetir esto mismo para los valores de r del intervalo discretizado.



Red elástica

Para un valor de r , determinar el valor de α que minimice el error para diferentes valores de α



Red elástica

Repetir esto para obtener la función de densidad. El valor de α obtenido minimiza el error.



Red elástica

Repetir esto mismo para los valores de r del intervalo discretizado

