



Clase 15 - Semana 15

Machine Learning

Universidad de Oriente
Facultad de Ingeniería y Arquitectura

08 de mayo del 2026


Método de los K vecinos más cercanos

En algunas ocasiones, en vez de emplear una técnica basada en un modelo, se puede utilizar una técnica basada en las propias observaciones, es decir, utilizar una técnica basada en los ejemplos. En los problemas de clasificación, podemos emplear el método de los K -vecinos más cercanos, más conocido como KNN, por sus siglas en inglés.

El método, clasifica las nuevas observaciones basándose en las observaciones ya existentes, es decir, las observaciones de entrenamiento. Para ello, si se define K como un número entero positivo y siendo x_0 una nueva observación que se quiere clasificar. Lo primero que se realiza en el método es identificar los K puntos más cercanos a x_0 , representados por N_0


Método de los K vecinos más cercanos

Para comprender mejor como funciona el método, supongamos el siguiente ejemplo sencillo. Se tienen 2 categorías posibles: “apto”, “no apto” y 2 variables predictoras continuas (X_1 y X_2) que se corresponden con los resultados normalizados obtenidos en un test psicotécnico.



Método de los K vecinos más cercanos


Si observamos la figura, vemos que con $K = 3$ deberíamos escoger los $K = 3$ puntos más cercanos a x_0 y calcular las probabilidades. En este caso, dado que dos de los tres puntos más cercanos son “apto” y el otro “no apto” se tendría que



Método de los K vecinos más cercanos

$$P(Y = \text{apto} | X = x_0) = 2/3; \quad P(Y = \text{No apto} | X = x_0) = 1/3;$$

Escogiendo el valor que obtiene una mayor probabilidad, decidiríamos que la nueva observación x_0 sería apta. Además, es posible determinar las distintas regiones de clasificación sin necesidad de tener una observación nueva



Método de los K vecinos más cercanos

El valor de K , tiene un gran efecto sobre el clasificador: cuando K es un valor bajo, las fronteras entre las regiones pueden ser más flexibles, y en cambio, cuando K es grande, estas fronteras son más rígidas. Un buen modo de saber que K escoger es emplear VC para obtener al k óptimo que minimice el error de clasificación en nuestro problema.

Además, cuando la variable de salida es binomial, es conveniente que el valor de k seleccionado sea un número impar, para que no haya puntos en los que las probabilidades de ser de la clase j sea la misma. En cambio, cuando estamos ante un problema multinomial, es posible que se produzca algún empate. Para resolver este inconveniente se puede asignar un peso a los vecinos de modo que tengan un mayor peso los vecinos más cercanos en la estimación de la categoría de la observación.

Aplicación en Python del método de los K vecinos más cercanos

Para aplicar el método de los K vecinos más cercanos es necesario realizar los siguientes pasos:

- Estandarizar las variables predictoras. Como se van a definir las distancias a las observaciones de entrenamiento es necesario que todas las variables tengan una misma escala para que sean comparables entre sí. Esto se va a conseguir estandarizando las variables predictoras.
- Ajustar el parámetro K que minimice el error de clasificación utilizando validación cruzada. Para ello se emplea la función `KNeighborsClassifier()` de la librería `sklearn.neighbors` donde el parámetro K se introduce como el argumento `n_neighbors`.
- Construir el clasificador con el valor de K óptimo para poder predecir nuevas observaciones