



Clase 16 - Semana 16

Machine Learning

Universidad de Oriente
Facultad de Ingeniería y Arquitectura

15 de mayo del 2026

Árboles de decisión

Un árbol de decisión consiste en una secuencia de condiciones sobre las distintas variables predictoras y su relación con la variable de respuesta. Estas condiciones se van sucediendo en distintos caminos del árbol, y por tanto, se van dividiendo las distintas posibilidades en ramas. Estas ramas, así pues, representan divisiones del espacio de los predictores en diferentes regiones.

Una vez definido el árbol, para poder realizar predicciones, habitualmente se emplea la media o la moda de la región a la cual pertenece dicha observación. Los métodos basados en árboles de decisión son simples y son fáciles de interpretar, aunque suelen tener unas capacidades de ajuste y de predicción peores que otro tipo de métodos como pueden ser la regresión penalizada.


Funcionamiento del árbol de decisión

Sin embargo, para mejorar esta capacidad predictiva han aparecido los métodos de ensamble, en los que se combinan muchos de estos árboles, obteniéndose resultados de predicción mucho mejores (aunque a expensas de la interpretabilidad del modelo)

Para explicar el funcionamiento de un árbol de decisión, empezaremos utilizando un problema de clasificación, y posteriormente veremos su contrapartida en el modelo de regresión. En concreto, se va a emplear el conjunto de datos Iris, que es un conjunto de datos muy empleado en multitud de manuales y softwares estadísticos. El conjunto de datos Iris consiste en diferentes medidas sobre 150 flores de 3 especies distintas: Iris Setosa, Iris versicolor y Iris virginica

Funcionamiento del árbol de decisión

Para construir un árbol de decisión sobre este conjunto de datos, se van a emplear únicamente dos variables predictoras: la longitud del pétalo y la anchura del pétalo.



Funcionamiento de un árbol de decisión

En esta figura se muestran las decisiones que se siguen para poder clasificar las observaciones organizadas en nodos. Estos nodos se pueden identificar por la profundidad (depth) que ocupan (en este ejemplo tenemos los niveles de profundidad 0 ó raíz, 1 y 2) y por su posición (izquierda o derecha).

Es interesante hacer notar que una de las cualidades de los árboles de decisión es que no es necesario escalar las variables predictoras (por ejemplo, estandarizándolas), con lo que se simplifica el proceso de resolución de los problemas.


Medidas de impureza

- **Gini:** Por último, en cada nodo se tiene la medida de impureza de Gini. Se dice que un nodo es “puro” si todas las observaciones del nodo son de la misma clase ($\text{gini}=0$).
- **Entropía:** La medida que viene por defecto para calcular los árboles de decisión en Scikit-Learn es la medida de impureza de Gini, pero también se puede seleccionar la entropía

En la mayoría de las ocasiones, ambas medidas arrojan árboles de decisión muy similares. Gini tiene un coste computacional algo menor, por lo que parece una buena decisión por defecto

Visualización del árbol de decisión

La ilustra la partición del espacio generada por el árbol de decisión del ejemplo. La línea vertical sólida corresponde a la decisión del nodo raíz, definida por la longitud del pétalo.



Visualización del árbol de decisión

La región ubicada a la izquierda de esta línea es pura, ya que contiene únicamente flores de la especie Iris setosa; por ello, no requiere más divisiones.

En cambio, la región de la derecha es impura. Por esta razón, el nodo de profundidad 1 divide nuevamente dicha región mediante la condición. Esta segunda separación se representa mediante una línea discontinua.

Hiperparámetros del modelo

Los árboles de decisión no necesitan realizar muchas suposiciones sobre la muestra de entrenamiento (en contraposición con, por ejemplo, los modelos lineales donde se asume que las relaciones son lineales). Si no se le añade ninguna restricción, la estructura del árbol se adaptará a la muestra de entrenamiento realizando un ajuste muy exacto. Normalmente, demasiado exacto, lo que va a producir problemas de sobreajuste.

Para evitar el sobreajuste en la muestra de entrenamiento (que conllevará a una mala predicción de observaciones no empleadas para el entrenamiento del modelo) es necesario restringir la libertad del árbol de decisión durante su creación.


Hiperparámetros del modelo

Una manera sencilla de evitar el posible sobreajuste del árbol es fijar un número de profundidad máxima, es decir, del número de divisiones sucesivas que se realizan. En Scikit-Learn, se puede emplear el argumento `max_depth`, como hemos visto anteriormente, siendo conscientes de que por defecto no lleva ninguna restricción. Otras maneras de actuar sobre los parámetros del modelo y tratar de reducir un posible sobreajuste son:

- `min_samples_split` : El mínimo número de muestras que puede tener un nodo para que se pueda dividir.
- `min_samples_leaf` : El mínimo número de muestras que puede tener un nodo hoja.
- `min_weight_fraction_leaf` : Como el anterior, pero cuando se utilizan pesos en las observaciones.
- `max_leaf_nodes`: Máximo número de nodos hoja.
- `max_features`: El máximo número de variables que son consideradas por el algoritmo para decidir cada división

Regresión utilizando árboles de decisión


Hasta ahora hemos visto cómo funcionan los árboles de decisión para problemas de clasificación. No obstante, también pueden ser empleados para resolver problemas de regresión. Para este fin, podemos emplear la clase `DecisionTreeRegressor` del paquete Scikit-Learn. Se realiza, a modo de ejemplo, el entrenamiento de un conjunto de datos consistentes en una regresión cuadrática con algo de ruido.



Inconvenientes de los árboles de decisión

Los árboles de decisión tienen muchas ventajas: son sencillos de implementar, fáciles de entender e interpretar, versátiles y permiten resolver tanto problemas de clasificación como de regresión. Sin embargo, también tiene algunas limitaciones.

- Los árboles funcionan con divisiones de las regiones perpendiculares a los ejes de las variables, por lo cual, son sensibles ante rotaciones de los datos de la muestra de entrenamiento.



Inconvenientes de los árboles de decisión

- Son sensibles ante pequeñas variaciones en las observaciones de la muestra de entrenamiento.

